


5 Hierarchické indexy (specializace WDOP)

1. Definujte datovou strukturu B-strom.
2. Uvažujte následující neredundantní B-strom stupně 3. Vložte do něj hodnotu 45 a následně smažte hodnotu 9. Nakreslete stav po každé z operací.



3. V relačních databázových systémech se ovšem pro indexaci sloupců využívají především B+ stromy. Vysvětlete, jak se liší od B-stromu, a co tyto modifikace v tomto kontextu přinášejí za výhody.

Nástin řešení Odpověď 1.


B-stromem stupně m rozumíme strom splňující následující podmínky:

- Kořen má alespoň 2 potomky, pokud není list.
- Každý uzel (kromě kořene) má alespoň $\lceil m/2 \rceil$ potomků.
- Každý uzel má nejvýše m potomků (stupeň).


- Každý uzel obsahuje $k - 1$ klíčů, kde k je počet potomků (tedy počet klíčů = počet potomků - 1).
- Klíče v uzlu jsou uspořádány vzestupně a rozdělují intervaly hodnot pro podstromy:
 - klíče v prvním podstromu $<$ první klíč,
 - klíče mezi i -tým a $(i + 1)$ -ním potomkem jsou mezi i -tým a $(i + 1)$ -ním klíčem,
 - klíče v posledním podstromu $>$ poslední klíč.
- Všechny listy se nacházejí na stejné úrovni (strom je vyvážený).

Odpověď 2.

Operace 1:



Operace 2:



Odpověď 3.

B+ strom:

- Vnitřní uzly obsahují pouze klíče (ne data).
- Všechna data jsou uložena až v listech.
- Listy jsou navíc mezi sebou propojené (lineární seznam).
- Výhody: rychlejší sekvenční procházení, efektivnější rozsahové dotazy.

6 Moderní databázové systémy (specializace WDOP)

Uvažujte následující situaci: Chceme vhodně reprezentovat entity *kniha*, *autor* a *vydavatelství* a vztahy mezi nimi zachycující kde byla kniha vydána, kdo ji napsal a zda jsou dva autoři přátelé. Dále chceme vyhodnocovat např. následující dotaz: "Které knihy napsal Dan Brown s někým, kdo nepatří do jeho přátel?"

1. Demonstrujte, jak byste taková data reprezentovali v grafové databázi jako např. neo4j, a jak by bylo možné dotaz vyjádřit např. v jazyce Cypher. (Je možné využít i jinou grafovou databázi podobného typu nebo jazyk. Pak specifikujte, o které jde. Není požadována absolutně přesná syntaxe jazyka, ale je třeba demonstrovat správnou znalost jeho základních principů.)
2. Naznačte (stačí schematicky, ne nutně přímo v jazyce SQL), jak by bylo možné stejnou situaci reprezentovat v tradiční relační databázi. Porovnejte, jak se tyto dva přístupy liší, jaké mají výhody a nevýhody (v tomto případě, popř. i obecně).

Nástin řešení Odpověď 1.

Reprezentace:

- Uzly: (Autor {jmeno}), (Kniha {nazev}), (Vydavatelstvi {nazev})
- Hrany:
 - (Autor) - [:NAPSAL] -> (Kniha)

- (Kniha)-[:VYDAL]->(Vydavatelstvi)
- (Autor)-[:PRITEL]-(Autor)

Dotaz:

```
MATCH (dan:Autor {jmeno: "Dan Brown"})-[:NAPSAL]->(k:Kniha)-[:NAPSAL]-(spoluautor:Autor)
WHERE dan <> spoluautor
AND NOT (dan)-[:PRITEL]-(spoluautor)
RETURN DISTINCT k.nazev;
```

Odpověď 2.

Reprezentace:

- **Autor** (id_autor **PK**, jméno)
- **Vydavatelství** (id_vydavatelstvi **PK**, název)
- **Kniha** (id_kniha **PK**, název, id_vydavatelstvi **FK** → **Vydavatelství**)
- **Napsal** (id_autor **FK** → **Autor**, id_kniha **FK** → **Kniha**, **PK** = (id_autor, id_kniha))
- **Přítel** (id_autor1 **FK** → **Autor**, id_autor2 **FK** → **Autor**, **PK** = (id_autor1, id_autor2))

V relační databázi by se dotaz skládal z několika drahých spojení tabulek. Komplikované by bylo, pokud bychom chtěli vyjádřit např. přátele přátel, nebo obecně rekurzi. Složitě je i přidávání nových typů vztahů.

7 Vyhledávání na webu (specializace WDOP)

Do databáze dokumentů bylo zaindexováno prvních pět dokumentů. Data byla uložena v podobě matice, kde sloupce reprezentují jednotlivé termíny a řádky dokumenty.

	A	B	C	D	E
D_1	1	0	1	1	0
D_2	0	1	1	0	1
D_3	1	1	1	0	0
D_4	0	1	0	1	1
D_5	1	0	1	0	1

Nad touto databází byly implementovány dvě klientské aplikace. První z nich podporuje boolský model vyhledávání a druhá model vektorový. Uživatel, pro něhož databáze obsahuje dva relevantní dokumenty D_2 a D_3 , položil prostřednictvím první aplikace dotaz "A and (B or C)" a prostřednictvím druhé aplikace dotaz "(1, 1, 1, 0, 0)".

1. Vysvětlíte, jak se ve vektorovém modelu vyhodnocuje Kosinova míra podobnosti. Určete, jaká ohodnocení přidělí dokumentům první aplikace, a jaká ohodnocení jim přidělí aplikace druhá, pokud používá právě Kosinovu míru. Jaké dokumenty jednotlivé aplikace vrátí jako odpověď a v jakém pořadí?
2. Popište, co znamenají pojmy přesnost a úplnost pro vyhodnocení efektivity vyhledávacího modelu a spočítejte je pro odpovědi poskytnuté výše uvedenými aplikacemi pro položené dotazy.
3. Lze nad těmito zaindexovanými dokumenty prostřednictvím jednotlivých klientských aplikací položit takový dotaz, který by vrátil právě a pouze oba relevantní dokumenty? Pokud ano, jak by dotaz vypadal? Pokud ne, proč?

Nástin řešení

1. Kosinova míra podobnosti dvou k -rozměrných vektorů $\vec{D}$ a $\vec{q}$ se spočte jako $(\vec{D} \cdot \vec{q}) / (|\vec{D}| \cdot |\vec{q}|) = \sum_{n=1}^k (D_i * q_i) / \sqrt{\sum_{n=1}^k D_i^2} / \sqrt{\sum_{n=1}^k q_i^2}$. Boolský model ohodnotí dokumenty vyhovující podmínce hodnotou 1 (true), ostatní hodnotou false (0). V daném případě budou ohodnocení po řadě 1, 0, 1, 0, 1 a aplikace vrátí dané tři dokumenty v neurčeném pořadí. Vektorový model ohodnotí dokumenty po řadě hodnotami $2/\sqrt{3}/\sqrt{3}$, $2/\sqrt{3}/\sqrt{3}$, $3/\sqrt{3}/\sqrt{3}$, $1/\sqrt{3}/\sqrt{3}$, $2/\sqrt{3}/\sqrt{3}$, tedy hodnotami $2/3$, $2/3$, $3/3$, $1/3$, $2/3$. Model vrátí všech pět dokumentů. D_3 bude první, D_4 bude poslední, pořadí ostatních nebude určeno.

2. Přesnost P se získá jako podíl počtu vrácených relevantních dokumentů a počtu vrácených dokumentů. Uplnost R se získá jako podíl počtu vrácených relevantních dokumentů a počtu všech relevantních dokumentů. První vyjadřuje pravděpodobnost, že vrácený dokument je relevantní, druhá pravděpodobnost, že relevantní dokument je vrácený. V případě Boolského modelu získáme hodnoty $P = 1/3$ a $R = 1/2$. V případě vektorového modelu získáme hodnoty $P = 2/5$ a $R = 2/2$.
3. V případě Boolského modelu by šlo napsat podmínku například "B and C". V případě vektorového modelu jednička na libovolné pozici do odpovědi zařadí i nějaký nerelevantní dokument. Dotaz "(0, 1, 1, 0, 0)" by vrátil požadované dokumenty na prvních dvou místech, ale nasledované i zbylými dokumenty.

8 Transakční rozvrhy (specializace WDOP)

Jsou dány dva transakční rozvrhy S_1 a S_2 :

S_1 :	T_1	T_2	T_3
1)	$R(A)$		
2)		$W(B)$	
3)			$W(A)$
4)	$R(B)$		
5)	COMMIT		
6)		$R(A)$	
7)		COMMIT	
8)			$W(B)$
9)			COMMIT

a

S_2 :	T_1	T_2	T_3
1)	$R(A)$		
2)	$R(B)$		
3)	COMMIT		
4)		$W(B)$	
5)		$R(A)$	
6)		COMMIT	
7)			$W(A)$
8)			$W(B)$
9)			COMMIT

1. Definujte konfliktovou ekvivalenci rozvrhů a rozhodněte, zda jsou rozvrhy S_1 a S_2 konfliktově uspořadatelné. Svě rozhodnutí zdůvodněte.
2. Je rozvrh S_1 zotavitelný? Svě rozhodnutí zdůvodněte. Pokud ne, navrhněte, zda a jak by šel zotavitelným učinit, aniž by se změnilo vzájemné pořadí čtení a zápisů v rozvrhu.
3. Je zaručeno, že oba rozvrhy S_1 a S_2 , pokud by byly spuštěné na stejných datech, povedou ke shodnému výslednému stavu databáze? Svě rozhodnutí zdůvodněte.

Nástin řešení

1. Dva rozvrhy jsou konfliktově ekvivalentní, pokud v obou všechny dvojice konfliktních operací (stejná proměnná, jiná transakce, ne dvojice čtení) probíhají ve stejném relativním pořadí. S_1 je konfliktově uspořadatelný. Dvojice operací 1-3, 3-6, 2-4 a 2-8 mají stejné relativní pořadí, jaké by měly v sériovém rozvrhu $T_2 T_1 T_3$. Lze ukázat i na precedenčním grafu, který nebude obsahovat cykly. Rozvrh S_1 je sám o sobě sériový, a je tedy konfliktově ekvivalentní sám se sebou.
2. Ne. Operace 4 čte nepotvrzenou hodnotu, zapsanou v 2, ale T_1 potvrzuje dříve, než T_2 . Podobně čte operace 6 nepotvrzenou hodnotu, zapsanou v 3, ale T_2 potvrzuje dříve, než T_3 . Pokud se nemá prohodit pořadí čtení a zápisů v rozvrhu, je potřeba s COMMITem v T_2 počkat, až skončí T_3 . S COMMITem v T_1 je třeba počkat, až opožděně skončí T_2 .

3. Není. S_1 je konfliktově ekvivalentní s $T_2 \ T_1 \ T_3$, ale ne s $T_1 \ T_2 \ T_3$. V prvním rozvrhu čte T_1 hodnotu A zapsanou v T_2 . Ve druhém čte původní hodnotu v databázi. Zbytek transakce a celkový výsledek tedy může být jiný.